

Homework 2

深度学习与空间智能

基于深度神经网络的视觉识别实验报告

花卉图像分类、道路车辆检测与图像分割

成员	学号	主要分工
朱宇玄	25110980033	花卉图像分类实验
钱玲萱	24110980018	道路车辆检测与跟踪实验
吉张林	25110980010	图像分割实验

GitHub 项目地址:

<https://github.com/MayRainStop/vision-classification-detection-segmentation>

模型权重网盘地址:

https://drive.google.com/drive/folders/11rpbLTSrK4TePYEZGx1LH_xuVx3fbTB9?usp=sharing

摘要

本文围绕三类典型视觉识别问题展开实验: 细粒度花卉图像分类、道路车辆检测与跟踪、图像分割。花卉分类实验使用 Oxford 102 Flowers 数据集, 系统比较 ResNet baseline、ImageNet 预训练与从零训练、SE/CBAM 注意力模块、ViT/Swin Transformer 以及 ConvNeXt 等现代卷积网络; 最终 ConvNeXt-Tiny 在 384px 输入和 10 个随机种子下取得 $95.60\% \pm 0.61\%$ 的测试准确率。车辆检测实验使用 YOLOv8s 在道路车辆数据集上训练检测器, 验证集 mAP50 为 0.520, 并结合 ByteTrack 完成跟踪 ID 显示、越线计数和遮挡失败分析。图像分割实验从零实现轻量 U-Net, 在 Stanford Background / ICCV09 风格数据上比较 Cross-Entropy、Dice 与组合损失, 组合损失取得最高验证集 mIoU 0.6531。实验结果表明, 预训练特征、注意力机制、输入分辨率、检测稳定性和区域重叠损失都会显著影响视觉识别系统的最终泛化性能。

1 引言

深度学习视觉系统通常可以分为图像级识别、目标级检测跟踪和像素级语义理解三个层次。图像分类关注整张图片属于哪个类别; 目标检测需要在图像或视频中定位多个实例; 图像分割则要求对每个像素进行类别判定。三类问题对应不同的监督信号、模型结构和评价指标, 也体现了深度神经网络在空间智能问题中的不同建模方式。

本文实验分为三个部分。第一部分研究 Oxford 102 Flowers 细粒度图像分类, 该数据集每类训练样本很少, 适合分析 ImageNet 预训练、注意力模块和现代 backbone 对小样本分类的影响。第二部分研究道路车辆检测与跟踪, 重点是 YOLOv8 检测器、ByteTrack 轨迹维持和遮挡场景下的 ID 跳变。第三部分研究图像分割, 使用手写 U-Net 比较不同损失函数对 mIoU 的影响。

本文的写作重点放在实验方法、训练设置、定量结果和结果分析上。检测结果使用 precision、recall 和 mAP; 分割结果使用 pixel accuracy 和 mIoU。

2 花卉图像分类实验

2.1 数据集与预处理

花卉分类实验使用 Oxford 102 Category Flower Dataset。数据集共包含 8189 张花卉图像，类别数为 102。每个类别对应一种花卉，图像具有明显的细粒度分类特征：不同类别之间常常只在花瓣形状、颜色组合、花蕊结构、局部纹理或拍摄角度上存在差异。因此，该问题比普通粗粒度图像分类更依赖高质量特征表示。

实验中严格使用数据集官方划分文件。其中 `setid.mat` 保存训练集、验证集和测试集的图像编号，`imagelabels.mat` 保存每张图片的类别标签。读取标签时，代码将 MATLAB 中从 1 开始的类别编号转换为 PyTorch 中从 0 开始的类别编号。

表 1: Oxford 102 Flowers 官方数据划分

数据子集	样本数	类别数	用途
训练集	1020	102	参数学习与数据增强
验证集	1020	102	模型选择与 early stopping
测试集	6149	102	最终泛化性能评估

图 1 给出了数据集中不同类别的代表性样例。可以看到，不同花卉类别之间往往只在颜色分布、花瓣形状、局部纹理和拍摄视角上存在细微差异；同时每类训练图像只有 10 张，这也是后续预训练和数据增强对结果影响明显的原因。




图 1: Oxford 102 Flowers 数据集样例

为了适配 torchvision 中的 ResNet、ConvNeXt、ViT 和 Swin 模型，基础实验使用 224×224 输入尺寸；后续进一步补充了 ConvNeXt-Tiny 384px 输入实验。训练阶段采用随机裁剪和颜色扰动以缓解小训练集带来的过拟合，验证和测试阶段则使用确定性的 `resize` 与 `center crop`，保

证模型选择和最终测试结果稳定可复现。

- 训练集: RandomResizedCrop(image_size, scale=(0.7, 1.0))、随机水平翻转、亮度/对比度/饱和度扰动;
- 验证集和测试集: 先 resize 到约 $1.14 \times$ 目标尺寸, 再进行 center crop;
- 归一化: 使用 ImageNet 均值 (0.485, 0.456, 0.406) 与标准差 (0.229, 0.224, 0.225);
- 损失函数: 使用 CrossEntropyLoss, 并在主要实验中加入 label smoothing。

2.2 模型结构

ResNet baseline

Baseline 使用 ResNet-18 和 ResNet-34。对于 ImageNet 预训练实验, 模型主体加载 torchvision 中的 ImageNet-1K 预训练权重, 仅将最后的全连接分类层替换为 102 类输出:

$$z = f_{\theta}(x), \quad p = \text{softmax}(Wz + b), \quad p \in \mathbb{R}^{102}. \quad (1)$$

从零训练实验使用相同结构, 但不加载 ImageNet 权重, 全部参数随机初始化后在 Oxford 102 数据集上训练。由于训练集仅 1020 张图像, 从零训练的模型更容易受到样本规模限制, 实验结果也可用于衡量预训练对小样本细粒度分类的贡献。

SE 与 CBAM 注意力模块

在 CNN 注意力实验中, 本文分别构建了 ResNet-18-SE、ResNet-34-SE、ResNet-18-CBAM 与 ResNet-34-CBAM。实现方式是在 ResNet 的 layer4 后加入注意力模块, 使模型在高层语义特征上重新分配通道或空间权重。

SE-block 通过全局平均池化得到通道描述, 再使用两层 1×1 卷积完成压缩与激励:

$$s = \sigma(W_2 \delta(W_1 \text{GAP}(F))), \quad F_e = F \odot s. \quad (2)$$

CBAM 在 SE 式通道注意力之外进一步加入空间注意力。通道注意力使用平均池化与最大池化两条分支, 空间注意力则在通道维度上计算 average map 和 max map 后使用 7×7 卷积生成空间权重。这样模型不仅能判断“哪些通道更重要”, 也能判断“图像中哪些区域更重要”。

Transformer 与现代卷积网络

除 CNN baseline 和注意力模型外, 本实验还训练了 ViT-B/16 与 Swin-T。ViT-B/16 将图像切分为 patch 后通过自注意力建模全局关系; Swin-T 则使用 shifted window attention, 在局部窗口内计算注意力并通过窗口移动实现跨窗口信息交换。二者均使用 ImageNet 预训练权重, 并将最后分类头替换为 102 类输出。

现代卷积网络实验补充了 ResNet-50、ResNet-101、EfficientNet-B0、EfficientNet-B3 和 ConvNeXt-Tiny。补充这些模型的目的是检查在 Swin-T 之外, 现代 CNN 架构是否能在小样本细粒度分类中提供更稳定的泛化能力。最终结果表明, ConvNeXt-Tiny 配合 384px 输入取得了最高且更稳定的多随机种子平均测试准确率。

2.3 实验设置

正式实验在 GPU 环境中完成。训练过程中每个 epoch 都记录训练集 loss、训练集 accuracy、验证集 loss、验证集 accuracy 和当前学习率。每当验证集 accuracy 刷新最高值时保存 checkpoint；若连续若干个 epoch 未提升，则 early stopping。最终测试时加载验证集表现最好的 checkpoint，而不是最后一个 epoch 的参数。

表 2: 花卉分类训练策略

项目	设置
优化器	AdamW
学习率调度	CosineAnnealingLR
最大 epoch	200
Early stopping	监控验证集 accuracy
损失函数	CrossEntropyLoss, 可选 label smoothing
评价指标	validation accuracy 与 test accuracy
模型选择	保存验证集 accuracy 最优 checkpoint

基础网格包含 CNN 与 Transformer 两部分。CNN 网格包含 baseline、SE、CBAM 和从零训练模型；Transformer 网格包含 ViT-B/16 与 Swin-T。完整搜索空间如表 3 所示。

表 3: 花卉分类基础超参数搜索空间

组别	模型	设置	学习率	Batch size	Label smoothing
CNN	ResNet-18	baseline	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-34	baseline	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-18	SE 模块	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-34	SE 模块	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-18	CBAM	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-34	CBAM	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-18	从零训练	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
CNN	ResNet-34	从零训练	$1 \times 10^{-3}, 3 \times 10^{-4}$	32, 64	0, 0.1
Transformer	ViT-B/16	预训练	$3 \times 10^{-4}, 1 \times 10^{-4}$	16, 32	0, 0.1
Transformer	Swin-T	预训练	$3 \times 10^{-4}, 1 \times 10^{-4}$	16, 32	0, 0.1

CNN 网格中 weight decay 取 1×10^{-4} 和 1×10^{-5} ；Transformer 网格中 weight decay 固定为 1×10^{-4} 。在基础网格基础上，后续继续进行了扩展 CNN、随机种子重复、ConvNeXt 最终检查、384px 分辨率扩展和小规模调参。最终花卉分类部分共纳入 303 次训练结果用于比较分析。

表 4: 花卉分类模型比较范围

比较组别	训练次数
CNN baseline、SE/CBAM 与 scratch/pretrained 网络	128
ViT-B/16 与 Swin-T 网络	16
扩展预训练 CNN 网络	120
扩展 CNN 随机种子重复	3
补充重复实验	12
ConvNeXt 最终检查	10
ConvNeXt 384px 分辨率扩展	14
合计	303

2.4 总体分类结果

基础网格中, Swin-T 取得最高测试准确率 94.26%, 最优 CNN 模型为 ResNet-34-CBAM, 测试准确率为 92.15%。从零训练的 ResNet-34 虽然优于从零训练的 ResNet-18, 但测试准确率只有 55.44%, 与预训练模型存在非常明显的差距。

表 5: 基础网格中各模型/训练模式的最优结果

模型	设置	预训练	Batch size	Val Acc.	Test Acc.
Swin-T	Transformer	是	16	95.98%	94.26%
ViT-B/16	Transformer	是	32	95.00%	92.83%
ResNet-18	CBAM	是	64	94.12%	90.86%
ResNet-34	CBAM	是	64	93.92%	92.15%
ResNet-18	SE-block	是	32	93.63%	90.65%
ResNet-34	SE-block	是	32	93.43%	89.72%
ResNet-18	baseline	是	32	92.94%	89.97%
ResNet-34	baseline	是	64	92.65%	89.58%
ResNet-34	从零训练	否	32	61.67%	55.44%
ResNet-18	从零训练	否	32	59.12%	52.72%

扩展实验进一步显示, ConvNeXt-Tiny 在该数据集上比单次 Swin-T 最优结果更稳定。最终选择 ConvNeXt-Tiny 384px, 学习率 1×10^{-4} , weight decay 1×10^{-5} , batch size 16, label smoothing 0.1。该配置在 10 个随机种子上取得 $95.60\% \pm 0.61\%$ 的测试准确率。

表 6: 扩展模型关键结果对比

模型/实验组	图像尺寸	实验次数	学习率	WD	Val Acc.	Test Acc.
Swin-T 最优单次	224	1	0.0001	10^{-4}	95.98%	94.26%
Swin-T 重复实验	224	3	0.0001	10^{-4}	$96.05\% \pm 0.32\%$	$93.98\% \pm 0.26\%$
ConvNeXt-Tiny 224px 最优单次	224	1	0.0003	10^{-4}	96.67%	94.67%
ConvNeXt-Tiny 224px 稳定配置	224	10	0.0001	10^{-5}	$96.64\% \pm 0.45\%$	$94.71\% \pm 0.31\%$
ConvNeXt-Tiny 384px 最终配置	384	10	0.0001	10^{-5}	$97.28\% \pm 0.48\%$	$95.60\% \pm 0.61\%$




图 2: ConvNeXt-Tiny 输入分辨率与随机种子稳定性对比




图 3: 不同模型代表性测试准确率对比

2.5 训练过程可视化

图 4 展示了最终 ConvNeXt-Tiny 384px 配置中一个代表性随机种子的训练过程。该模型在前几个 epoch 内快速收敛，验证集准确率在第 3 个 epoch 已达到 93.43%，随后逐步提升并在第 31 个 epoch 首次达到最高验证准确率 97.75%。第 46 个 epoch 触发 early stopping，说明后期继续训练对验证集泛化性能已经没有稳定收益。




图 4: 最终 ConvNeXt-Tiny 384px 模型训练集与验证集准确率曲线

图 5 给出了同一模型的 loss 曲线。训练 loss 迅速下降并接近稳定，验证 loss 在前期下降明

显，后期有小幅波动。这一现象与细粒度小样本分类问题的特点一致：预训练模型可以很快拟合训练集，但验证集性能提升受类别间细微差异、数据增强随机性和训练样本规模共同限制。




图 5: 最终 ConvNeXt-Tiny 384px 模型训练集与验证集 loss 曲线

2.6 预训练消融实验

预训练消融实验的结论非常明显。采用 ImageNet 权重时，两个 ResNet 的测试准确率接近 90%；从零训练时仅约 53%–55%。具体而言，ResNet-18 从 52.72% 提升到 89.97%，ResNet-34 从 55.44% 提升到 89.58%。两组差距均超过 34%。

表 7: ImageNet 预训练与从零训练的对比

模型	初始化方式	Best epoch	Val Acc.	Test Acc.
ResNet-18	ImageNet 预训练	42	92.94%	89.97%
ResNet-18	随机初始化	102	59.12%	52.72%
ResNet-34	ImageNet 预训练	28	92.65%	89.58%
ResNet-34	随机初始化	96	61.67%	55.44%




图 6: ImageNet 预训练对 ResNet baseline 的提升

这一结果说明，Oxford 102 的训练集规模不足以让 ResNet 从随机初始化中学习到足够稳健的低层纹理、中层形状和高层语义特征。ImageNet 预训练提供了通用视觉特征，后续微调主要需要适配花卉类别边界，因此收敛速度更快，泛化性能也显著更高。

2.7 注意力模块分析

在预训练 ResNet baseline 的基础上加入注意力模块后，整体性能有所提升。ResNet-18 baseline 的测试准确率为 89.97%，加入 SE 后提升到 90.65%，加入 CBAM 后提升到 90.86%。ResNet-34-CBAM 的测试准确率达到 92.15%，是基础 CNN 组中测试集表现最高的模型。

表 8: 注意力模块与 CNN baseline 对比

模型	Val Acc.	Test Acc.	相对同深度 baseline 的变化
ResNet-18	92.94%	89.97%	—
ResNet-18-SE	93.63%	90.65%	+0.68%
ResNet-18-CBAM	94.12%	90.86%	+0.89%
ResNet-34	92.65%	89.58%	—
ResNet-34-SE	93.43%	89.72%	+0.14%
ResNet-34-CBAM	93.92%	92.15%	+2.57%




图 7: SE 与 CBAM 注意力模块的测试准确率对比

从结果看，CBAM 通常比 SE 更稳定。原因可能在于花卉分类不仅依赖通道语义，还依赖局部区域，例如花心、花瓣边缘和颜色纹理。CBAM 的空间注意力能够进一步强化这些判别区域，因此在 ResNet-18 和 ResNet-34 上均取得更好的测试表现。

2.8 Transformer 与 ConvNeXt 分析

Transformer 组整体优于基础 CNN 组。ViT-B/16 的最优测试准确率为 92.83%，Swin-T 的最优测试准确率为 94.26%。Swin-T 的优势主要来自两点：首先，shifted window attention 在局部窗口中建模，保留了类似 CNN 的局部归纳偏置，更适合花瓣纹理、边缘与局部形状；其次，窗口移动机制又允许跨区域信息交换，使模型能够同时利用局部细节和全局花型结构。

在扩展 CNN 实验中，ConvNeXt-Tiny 进一步超过了 Swin-T。ConvNeXt-Tiny 同样保留卷积网络的局部归纳偏置，但吸收了现代视觉模型的训练和结构设计。对于 Oxford 102 这样训练集很小、但测试集较大的细粒度分类问题，ConvNeXt-Tiny 的稳定性优于单次 Swin-T 最优结果。

2.9 超参数影响分析

从完整网格搜索和补充实验可以观察到以下规律。为避免正文表格过于冗长，基础网格中各模型在不同学习率、weight decay、batch size 和 label smoothing 下的完整验证集准确率汇总见附录 B；最终 ConvNeXt-Tiny 384px 主结果配置见附录 A。

1. 学习率: 对预训练 CNN 来说, 3×10^{-4} 在 224px 网格中通常比 1×10^{-3} 更稳定; Transformer 中 1×10^{-4} 的结果明显优于 3×10^{-4} , 说明预训练 Transformer 微调时更需要较小学习率。最终 ConvNeXt 384px 配置中, 1×10^{-4} 也优于 3×10^{-4} 的候选配置。
2. Batch size: CNN 中 batch size 32 和 64 都能取得较好结果; Transformer 中最优 Swin-T 使用 batch size 16。最终 ConvNeXt 384px 由于分辨率更高, 采用 batch size 16。
3. Label smoothing: 多数最优模型使用 label smoothing=0.1。该策略在小样本细粒度分类中能够缓解过度自信, 提升验证集稳定性。
4. Weight decay: 基础 CNN 网格中 1×10^{-4} 的最优结果更多; 最终 ConvNeXt 384px 配置使用 1×10^{-5} , 说明更强 backbone 与更高分辨率下可适当减弱权重衰减。
5. 训练轮数: 预训练模型通常在几十个 epoch 内达到最佳验证性能; 从零训练模型需要 90–100 个 epoch 以上才达到最佳点, 但最终泛化性能仍明显较低。

图 8 进一步把基础预训练 CNN 网格中的学习率和 batch size 关系可视化。每个格子保留同一组学习率与 batch size 下表现最好的 ResNet baseline、SE 或 CBAM 变体。结果显示, 3×10^{-4} 整体优于 1×10^{-3} , 而 batch size 64 在该网格中取得最高验证准确率。




图 8: 预训练 CNN 网格中学习率与 batch size 的影响

2.10 稳定性实验

最终报告采用 10 个随机种子的平均值作为主结果, 而不是挑选单个最高随机种子。虽然其中一个随机种子的单次测试准确率达到 96.50%, 但该值可能带有随机性; 10 个随机种子的平均值 $95.60\% \pm 0.61\%$ 更适合作为正式结论。

表 9: 最终 ConvNeXt-Tiny 384px 配置的 10 个随机种子结果

Seed	Best epoch	Epochs completed	Val Acc.	Test Acc.
7	30	45	97.06%	95.14%
42	39	54	97.84%	95.85%
99	32	47	97.55%	95.97%
123	51	66	97.75%	96.05%
314	31	46	97.75%	96.50%
512	13	28	96.67%	94.24%
1009	26	41	96.86%	95.54%
2024	34	49	96.76%	95.59%
2026	31	46	97.75%	95.46%
4096	35	50	96.86%	95.67%
平均 $\pm$ 标准差	—	—	97.28% $\pm$ 0.48%	95.60% $\pm$ 0.61%

2.11 测试集错误分析

为了进一步分析最终分类器的错误模式，本文选取最终实验组中测试准确率最高的 seed 314 checkpoint，在官方测试集上重新进行一次逐样本推理。该 checkpoint 对应 ConvNeXt-Tiny 384px 模型，单模型测试准确率为 96.50%，共正确分类 5934 张，错分 215 张。需要说明的是，报告主结论仍采用 10 个随机种子的平均值；这里使用 seed 314 的目的是观察一个代表性最优单模型在测试集上的具体错误分布。

由于 Oxford 102 的官方标注文件只提供类别编号，下面的错误分析沿用数据集中的 1–102 类编号。表 10 和图 9 展示了出现次数最多的类别混淆。最明显的错误是第 96 类被预测为第 97 类，共 10 张，占第 96 类测试样本的 14.08%；第 53 类被预测为第 46 类也出现了 9 次。其余混淆对的绝对次数明显更低，说明模型并不是在大范围类别上系统性失效，而是在若干细粒度边界上仍存在不确定性。

表 10: 最终 ConvNeXt-Tiny 384px 模型的主要错分类别对

排名	真实类别	预测类别	错分数量	占真实类比例
1	96	97	10	14.08%
2	53	46	9	12.33%
3	51	83	7	2.94%
4	23	97	5	7.04%
5	50	12	4	5.56%
6	51	75	4	1.68%
7	51	1	4	1.68%
8	51	19	4	1.68%




图 9: 最终 ConvNeXt-Tiny 384px 模型的高频错分类别对

图 10 进一步列出了一组代表性错分样例，并加入少量第 97 类正确识别样本作为参照：图中带有 ref 的条目表示第 97 类参考样本。可以看到，错分通常不是由图像完全失真导致的，而是与花瓣形状、花心结构、颜色组合、拍摄角度和遮挡等细节有关。例如第 96 类多次被预测为第 97 类，样例中花瓣轮廓和颜色分布非常接近；第 50 类与第 12 类的混淆则体现出黄色花卉在局部纹理和花型相似时仍然具有较强挑战性。这说明即使最终模型已经达到较高准确率，Oxford 102 的剩余错误仍主要来自细粒度视觉差异，而不是训练过程没有收敛或模型整体表达能力不足。




图 10: 最终 ConvNeXt-Tiny 384px 模型的错分样例与第 97 类参考样本；T 表示真实类别，P 表示预测类别，ref 表示正确识别的第 97 类参照样本

3 道路车辆检测与跟踪实验

3.1 数据集与模型设置

道路车辆检测实验使用 Road Vehicle Images Dataset。数据以 YOLO 检测格式组织，每个标注框由类别编号和归一化后的中心点、宽高表示。训练集包含 2704 张图像和 21764 个标注实例，验证集包含 300 张图像和 2584 个标注实例。数据集类别数为 21，覆盖 ambulance、bus、car、motorbike、rickshaw、suv、truck、van 等道路场景中常见交通参与者。相较于单一车辆类别检测，该数据集的难点在于类别之间外观相近、目标尺度差异较大，并且部分类别样本较少。

实验使用 YOLOv8s 作为检测器，并基于 yolov8s.pt 预训练权重微调。YOLO 系列模型将目标定位和类别预测放在同一个端到端网络中完成，适合道路视频中的实时检测。YOLOv8s 在模型规模和检测精度之间较为平衡，能够在有限计算资源下完成多类别车辆检测实验。训练时使用 AdamW 优化器，输入分辨率为 640，batch size 为 16，并保留 YOLO 默认的数据增强策略，包括 HSV 颜色扰动、随机平移、尺度缩放、水平翻转和 mosaic 增强。这些增强有助于提高模型对不同拍摄角度、光照条件和目标尺度的鲁棒性。

表 11: 道路车辆检测数据集概况

项目	数值
训练图像数	2704
验证图像数	300
训练集标注实例数	21764
验证集标注实例数	2584
平均每图实例数	8.11
检测类别数	21
输入标注格式	YOLO bounding box

图 11 给出了道路车辆数据中的标注样例。可以看到，同一图像中往往同时出现多辆车、行人相关交通工具以及远处小目标，标注框尺度差异明显；部分目标还会被车体、道路设施或画面边缘遮挡。这些因素使检测器不仅需要区分类别，还需要在密集场景中保持较好的框定位精度。

进一步统计训练集和验证集的全部 YOLO 标注，类别实例分布如图 12 所示，横轴使用对数尺度。car、rickshaw、bus、three wheelers-CNG 和 motorbike 是最主要的五类，共占据大部分训练信号；而 garbagevan、policecar、scooter、army vehicle、taxi 等类别样本很少。类别长尾分布会使模型更偏向高频类别，同时也解释了后续部分类别虽然整体检测器可用、但类别级 mAP 差异较大的现象。对于 van、suv、pickup、minivan 等外观相近类别，样本数量并不是唯一瓶颈，车辆轮廓和拍摄角度的相似性同样会增加混淆。



图 11: Road Vehicle Images Dataset 标注样例




图 12: 道路车辆检测类别实例分布

表 12: YOLOv8s 训练配置

Setting	Value
Model	YOLOv8s
Pretrained weights	yolov8s.pt
Dataset classes	21
Image size	640
Batch size	16
Optimizer	AdamW
Initial learning rate	0.001
Max epochs	100
Early stopping patience	10
Actual epochs	37
Best epoch	27

训练与验证过程同时保存了 Ultralytics 本地可视化文件,并同步到 Weights & Biases。W&B 项目为 HW2_Road_Vehicle_Detection,对应运行行为 v7f1dr6d / yolov8s_adamw_lr001_v2。报告中的训练曲线、PR/F1 曲线和混淆矩阵主要来自本地 `plots=True` 生成的可视化结果,并与 W&B 记录的训练过程一致。

训练原计划最多运行 100 个 epoch,但验证集指标在第 27 个 epoch 附近达到较优水平,随后提升不再稳定,最终触发 patience 为 10 的 early stopping,并在第 37 个 epoch 停止。训练过程显示,模型的 box loss、classification loss 和 DFL loss 均随 epoch 增加而下降,说明网络逐渐学会了车辆位置回归和类别判别;但验证集 mAP 在后期存在波动,反映出多类别车辆检测中的小目标、遮挡和类别相似性仍会限制泛化表现。

3.2 检测结果

验证集指标如表 13 所示。Precision 为 0.667, Recall 为 0.412,说明检测结果中预测框的准确性较好,但仍有较多真实目标没有被召回。mAP50 为 0.520,说明在 IoU 阈值为 0.5 时,模型对主要车辆类别已经形成了可用的检测能力;mAP50-95 为 0.304,明显低于 mAP50,说明在更严格的定位标准下,框的位置精度和小目标定位仍是主要瓶颈。

表 13: 车辆检测验证集指标

Metric	Value
Precision	0.667
Recall	0.412
mAP50	0.520
mAP50-95	0.304

从训练曲线可以看到, mAP50 在前 20 多个 epoch 中持续提升,随后进入平台期并出现震荡。第 36 个 epoch 的 recall 曾达到 0.558,但 precision 降至 0.498;而最终最佳权重的 precision 更高、recall 较低,说明模型更倾向于保守预测。这种 precision-recall 权衡在道路车辆检测中比较常见:降低置信度阈值可以召回更多车辆,但也会引入更多误检;提高阈值则可以减少误检,但容易漏掉远处、被遮挡或尺寸较小的车辆。

表 14: 代表性类别 mAP50

Class	mAP50
car	0.790
rickshaw	0.733
three wheelers -CNG-	0.724
bus	0.663
truck	0.624
van	0.246
suv	0.188

类别级结果表明, car、rickshaw、three wheelers-CNG、bus 和 truck 等较常见或外观边界较清晰的类别 mAP50 较高。其中 car 的 mAP50 达到 0.790, 是最容易识别的类别之一; rickshaw 和 three wheelers-CNG 的检测效果也相对较好, 说明模型能够学习到这类交通工具的形状特征。相比之下, van 和 suv 的 mAP50 分别只有 0.246 和 0.188, 说明数据集中其他少样本或外观相似类别更容易互相混淆, 例如 minivan、van、suv、pickup 等类别之间的轮廓差异较细, 容易受到拍摄角度和遮挡影响。




图 13: YOLOv8s 训练曲线




图 14: YOLOv8s 检测阈值相关曲线




图 15: 车辆检测类别混淆与预测可视化

PR 曲线和 F1 曲线进一步说明, 检测器的性能并非由单一置信度阈值决定。对于后续视频跟踪而言, 过高的置信度阈值会导致遮挡帧中目标短暂消失, 使 tracker 缺少连续观测; 过低的阈值则会引入误检, 造成错误轨迹。因此, 检测模型本身的稳定性和推理阶段阈值选择都会影响最终视频分析效果。混淆矩阵也反映出多类别车辆检测中类别边界并不总是清晰, 尤其是尺寸和外观相近的车辆类型更容易发生类别跳变。

3.3 跟踪计数与遮挡分析

视频推理阶段对每帧调用 YOLOv8s 检测, 并通过 ByteTrack 维持轨迹。ByteTrack 的基本思想是同时利用高置信度和低置信度检测框进行轨迹关联, 从而尽量保留被短暂遮挡或置信度下降的目标。实验中推理置信度阈值设为 0.4, IoU 阈值设为 0.4; 输出视频在每个目标上绘制 bounding box 与 ID:<track_id> <class_name>, 同时绘制画面中线和累计越线数量。

表 15: 跟踪视频与可视化来源

项目	文件或来源	说明
输入视频	test2.mp4	时长约 23.75 s, 用于逐帧检测、跟踪和越线计数。
输出视频	tracking_analysis.mp4	时长约 23.73 s, 为 YOLOv8s + ByteTrack 推理后的可视化结果。
遮挡关键帧	frame_378/424/440.jpg	从输出视频中截取, 用于分析 ID switch 和类别跳变。
训练可视化	Ultralytics plots 与 W&B	包括 loss、mAP、PR/F1 曲线、混淆矩阵和验证集预测样例。

越线计数采用轨迹中心点判断。设画面竖直中线为 $x = W/2$, 每个 track id 保存上一帧中中心点横坐标 x_{t-1} 和当前帧中心点横坐标 x_t 。当满足

$$x_{t-1} < W/2 \leq x_t \quad (3)$$

时, 认为该目标从左向右越过计数线。为了避免同一目标重复计数, 实验使用已通过 ID 集合保存完成越线的 track id, 因此同一条轨迹只会被统计一次。该规则简单直观, 适合固定机位道路视频, 但它依赖 tracker ID 的连续性; 一旦目标在遮挡后被分配新 ID, 就可能造成重复计数或漏计。

遮挡分析帧显示: 当一辆较大的 SUV 在画面中遮挡较小车辆时, 检测框短暂缺失或类别不稳定, ByteTrack 无法可靠延续原轨迹, 因此会出现 ID 从 20 切换到 33 的情况; 另一个目标保持 ID 22, 但类别预测发生跳变。这说明最终跟踪质量不仅取决于 tracker, 也强依赖检测器在遮挡场景下的稳定性。




图 16: 遮挡导致的 tracking ID 跳变案例

从图中可以看到, 遮挡发生前目标具有稳定的检测框和 ID: Frame 378 中后方两辆白车分别保持 ID 20 和 ID 22, 前景红色 SUV 为 ID 26。到 Frame 424, 红色 SUV 与白车发生密集交汇, 后方白车被大面积遮挡, 原 ID 20 在遮挡后被重新识别为 ID 33, 形成 ID switch。Frame 440 中, 另一辆白车虽然维持了 ID 22, 但类别从 car 瞬时跳变为 suv。

ID 20 跳变的主要原因在于检测缺失和轨迹关联同时失效。ByteTrack 会先根据历史轨迹预测当前位置, 再用当前检测框与预测框的 IoU 进行匹配; 当目标被 SUV 长时间遮挡时, 检测框置信度下降甚至短暂消失, 低置信度二次匹配也无法提供可靠观测。同时, 后方白车尺度较小并在路口附近存在减速, 卡尔曼预测位置与重新出现的检测框之间容易产生偏差, 最终导致原轨迹被判定为丢失, 新出现的检测框被分配新的 ID。相比之下, ID 22 的遮挡时间较短, 重新出现时检测框与预测轨迹仍能匹配, 因此保持了原 ID。

类别跳变则更多来自检测器而非 tracker。ByteTrack 主要维护轨迹身份, 类别标签仍由每帧 YOLO 检测头给出; 当红色 SUV 占据画面主体、白车局部特征被遮挡或被邻近车辆污染时, 分类头容易受到干扰。类别级指标也支持这一点: car 的 mAP50 为 0.790, 而 suv 只有 0.188,

说明模型对 SUV 相关边界的判别更不稳定。该现象说明检测与跟踪并不是两个完全独立的环节：检测器如果在遮挡、远距离和类别相似情况下不稳定，后续轨迹关联就会失去可靠输入。实际系统中可以通过提高检测器召回率、调节 ByteTrack 的匹配阈值、加入运动模型约束或进行摄像机场景标定来缓解该问题。

4 图像分割实验

4.1 数据集与 U-Net 结构

图像分割实验使用 iccv09Data 中的 labels/*.regions.txt 作为语义标签，共包含 8 个类别：sky、tree、road、grass、water、building、mountain 和 foreground_object。与图像分类和目标检测不同，图像分割需要为每一个有效像素预测类别，因此模型既要理解全局场景语义，也要恢复局部边界和区域形状。标签中的负数像素表示未知区域，训练时统一映射为 ignore_index = 255，损失与指标统计时忽略这些像素。实验中输入图像统一缩放为 320×240 ，并使用固定随机种子从全部样本中随机抽取 15% 作为验证集。

图 17 给出了输入图像与语义标签样例。可以看到，天空、道路和建筑等大面积类别占据了多数像素，而 foreground_object、mountain 等类别面积较小，更容易受分辨率和下采样影响。因此，图像分割实验不能只依赖 pixel accuracy，还需要使用 mIoU 和 per-class IoU 来衡量区域边界和小类别恢复质量。



图 17: 图像分割数据与标签样例

模型采用手写轻量 U-Net，包括编码器下采样路径、瓶颈层特征提取、解码器上采样、Skip Connection 和最终 1×1 Conv 像素分类头。编码器逐层降低空间分辨率、提取高层语义信息；解码器逐层恢复分辨率并结合浅层特征，从而兼顾整体语义理解和边界细节恢复。

表 16: 轻量 U-Net 结构

模块	空间操作	通道数
Encoder 1	ConvBlock	32
Encoder 2	MaxPool + ConvBlock	64
Encoder 3	MaxPool + ConvBlock	128
Encoder 4	MaxPool + ConvBlock	256
Bottleneck	MaxPool + ConvBlock	512
Decoder	Transposed Conv + Skip Connection	256, 128, 64, 32
Head	1×1 Conv	8 classes

表 17: 图像分割训练配置

Setting	Value
Model	U-Net
Input size	320×240
Epochs	100
Batch size	8
Learning rate	3×10^{-4}
Optimizer	AdamW
Weight decay	1×10^{-4}
Validation split	Random 15%
Seed	42

4.2 损失函数设计

实验比较三种损失函数配置：

- Cross-Entropy Loss: 逐像素多分类监督，训练稳定；
- 手写 Dice Loss: 直接优化预测区域与真实区域的重叠程度；
- Cross-Entropy + Dice: 兼顾像素级分类稳定性与区域级重叠优化。

交叉熵损失对每个有效像素进行多分类监督，其形式为

$$\mathcal{L}_{CE} = -\frac{1}{|\Omega|} \sum_{i \in \Omega} \log p_{i,y_i}, \quad (4)$$

其中 Ω 表示非忽略像素集合， y_i 为像素 i 的真实类别， p_{i,y_i} 为模型对真实类别的预测概率。交叉熵训练稳定，但当类别面积差异较大时，大面积类别会在损失中占据更高权重。

Dice 系数直接衡量预测区域和真实区域的重叠程度。实验中手写实现多类别 Soft Dice Loss: 先对 logits 做 softmax，再将标签转换为 one-hot 表示，并用 `ignore_index` mask 去除未知像素。对第 c 类，Dice 系数为

$$Dice_c = \frac{2 \sum_i p_{i,c} g_{i,c} + \epsilon}{\sum_i p_{i,c} + \sum_i g_{i,c} + \epsilon}, \quad (5)$$

最终损失写为 $1 - \frac{1}{C} \sum_c Dice_c$ 。组合损失使用 $\mathcal{L}_{CE} + \mathcal{L}_{Dice}$ ，希望同时保留交叉熵的分类稳定性和 Dice 的区域重叠优化能力。

4.3 分割结果

三种损失函数在验证集上的最佳结果如表 18 所示。当前实验中，**Cross-Entropy + Dice** 取得了最高的验证集 $mIoU=0.6531$ ；Dice Loss 次之，为 0.6477；单独使用 Cross-Entropy 为 0.6436。三者的 pixel accuracy 都较高，但 $mIoU$ 的差异更能反映小类别与边界区域的恢复质量。

表 18: 三种损失函数验证集结果

Loss	Best epoch	Best Val mIoU	Best Val Pixel Acc.
Cross-Entropy	58	0.6436	0.8432
Dice	83	0.6477	0.8446
Cross-Entropy + Dice	66	0.6531	0.8489

为了进一步分析不同损失函数对各类别的影响，表 19 给出了验证集 per-class IoU。可以看到，sky、road 和 building 是相对容易的类别，而 mountain 是最难的类别。组合损失在大多数类别上都取得了最优或接近最优的表现，因此整体 $mIoU$ 最高。

表 19: 三种损失函数的 per-class IoU

Method	sky	tree	road	grass	water	building	mountain	foreground_object	Val mIoU
Cross-Entropy	0.8623	0.6661	0.8637	0.5477	0.6559	0.7384	0.2066	0.6077	0.6436
Dice	0.8655	0.6631	0.8602	0.5352	0.6490	0.7327	0.2670	0.6093	0.6477
Cross-Entropy + Dice	0.8745	0.6686	0.8654	0.5641	0.6605	0.7458	0.2333	0.6124	0.6531

4.3.1 单组训练曲线与总体对比

图 18 给出了三种损失函数在验证集上的 $mIoU$ 对比曲线。Cross-Entropy 在前期收敛较快，但后期提升有限；Dice 在中后期继续改善区域重叠质量；组合损失则在稳定性和最终效果之间取得了更好的平衡，最终达到最高验证集 $mIoU$ 。




图 18: 三种损失函数的验证集 $mIoU$ 对比曲线

图 19 展示了三组实验各自的训练曲线。三种方法都能稳定收敛，但组合损失在训练集和验证集两侧都表现出更好的综合平衡性。




图 19: 三种损失函数的单组训练曲线

图 20 给出了三组最佳模型对应的混淆矩阵。可以看出，sky、road 和 building 的识别效果最好，这几个类别在混淆矩阵对角线上的响应最强，说明模型能够较稳定地恢复它们的大面积区域结构。其中，天空通常位于图像上方且外观特征明显；道路和建筑在场景中也往往具有较稳定的空间位置与纹理模式，因此更容易学习。相比之下，mountain 是最难识别的类别，其 IoU 最低。一个可能的原因是山体在数据集中出现频率较低、像素占比偏小，并且在颜色和纹理上容易与 tree、grass 等自然场景区域混淆，因此模型更难为其学习到稳定且清晰的判别边界。




图 20: 三种损失函数对应的最佳混淆矩阵

4.3.2 样例预测分析

图 21 单独列出了样本 0000382 在三种损失函数下的预测结果。该样本同时包含天空、建筑、道路/地面、树木和前景目标，能够较直观地观察模型对大面积区域与小目标区域的处理差异。Cross-Entropy 更容易偏向主导类别；Dice 在局部区域连续性上更好；组合损失在整体结构稳定性和小区域恢复之间取得了较好的折中。




图 21: 样本 0000382 在三种损失函数下的预测结果

4.4 结果分析与结论

综合定量结果和可视化结果，可以得到以下结论：

- 仅使用 Cross-Entropy 能够提供稳定的像素级分类能力，但对小类别和边界区域的优化相对不足；
- Dice Loss 更直接面向区域重叠优化，因此在类别不平衡场景下表现更强；
- Cross-Entropy + Dice 在本实验设置下取得了最高的验证集 mIoU=0.6531，说明组合损失在稳定性和区域优化之间达到了更优折中。

因此，在当前数据划分和训练配置下，**Cross-Entropy + Dice** 是本实验中效果最好的损失函数配置。

5 综合讨论

三类实验体现了不同视觉问题的主要难点。花卉分类实验中，训练集每类只有 10 张图像，模型性能高度依赖预训练特征。ResNet 从零训练与 ImageNet 预训练之间超过 34% 的差距说明，小样本细粒度分类很难仅依靠目标数据集本身学习出稳健特征。注意力模块能进一步提升 CNN baseline，但收益小于更强 backbone 和更高分辨率输入带来的增益。

车辆检测实验的主要难点不只在检测框本身，也在视频中的时间连续性。YOLOv8s 的 mAP 指标显示，模型已经能大致定位主要车辆，但精确框回归和小目标检测仍有提升空间。视频跟踪部分进一步表明，即使单帧检测器在大部分帧中能识别车辆，遮挡、类别跳变和短暂漏检仍会影响 ByteTrack 的轨迹连续性，从而导致 tracking ID 变化。该现象说明检测跟踪系统的稳定性取决于检测器和 tracker 的共同作用，也取决于置信度阈值、IoU 阈值和越线规则的选择。

图像分割实验表明，三种损失函数都能够稳定训练轻量 U-Net，但组合损失在当前配置下取得了最佳综合效果。验证集结果显示，Cross-Entropy、Dice 和 Cross-Entropy + Dice 的最佳 mIoU 分别为 0.6436、0.6477 和 0.6531，其中组合损失最高。这说明仅使用逐像素交叉熵虽然能够提供稳定的分类监督，但引入 Dice 项后，模型在区域重叠和小类别恢复上会进一步受益。

从 per-class IoU 来看，sky、road 和 building 等大面积类别在三种方法下都相对容易，而 mountain 仍然是最难类别。Dice Loss 在 mountain 上优于单独的 Cross-Entropy，说明区域级优化对困难类别有帮助；而 Cross-Entropy + Dice 在 sky、tree、road、grass、water、building 和 foreground_object 等大多数类别上都取得了最优或接近最优的结果，因此最终整体 mIoU 最高。这个结果也说明，在图像分割任务中，pixel accuracy 往往更容易被大面积类别主导，而 mIoU 和 per-class IoU 更能真实反映不同类别的分割质量。

6 结论

本文完成了花卉图像分类、道路车辆检测与跟踪、图像分割三类视觉识别实验。花卉分类中，ConvNeXt-Tiny 384px 在 10 个随机种子上取得 $95.60\% \pm 0.61\%$ 的测试准确率，是本实验中最稳定的分类模型；预训练、注意力机制、输入分辨率和超参数选择均显著影响细粒度分类表现。车辆检测中，YOLOv8s 在验证集上取得 mAP50 0.520，并能结合 ByteTrack 完成跟踪 ID 显示和越线计数，但遮挡仍会造成 ID switch。图像分割中，手写轻量 U-Net 在当前实验设置下分别取得 Cross-Entropy 0.6436、Dice 0.6477 和 Cross-Entropy + Dice 0.6531 的最佳验证集 mIoU，其中最优配置为 Cross-Entropy + Dice，说明组合损失在像素级分类稳定性和区域重

叠优化之间达到了更好的平衡。

总体而言，三组实验从分类、检测跟踪和图像分割三个层次展示了深度视觉模型在空间智能问题中的应用方式。预训练特征提供了小样本识别的基础，检测器稳定性决定了跟踪质量，而像素级理解则需要结构设计和损失函数共同配合。

A 最终分类模型训练配置

表 20: 最终花卉分类主结果配置

项目	数值
模型	ConvNeXt-Tiny
初始化	ImageNet 预训练
Image size	384
Learning rate	1×10^{-4}
Weight decay	1×10^{-5}
Batch size	16
Label smoothing	0.1
Seeds	10
Mean validation accuracy	$97.28\% \pm 0.48\%$
Mean test accuracy	$95.60\% \pm 0.61\%$
Best single-seed test accuracy	96.50%

B 基础超参数搜索结果总表

附录表格按照模型家族分组给出基础网格搜索结果。表中单元格为对应配置在训练过程中取得的最佳验证集准确率，单位为百分比。为使表格与正文分析对应，附录仅保留验证集 accuracy; epoch 和 test accuracy 不在此处重复列出。

表 21: ResNet-18 预训练模型搜索结果总表

学习率	权重衰减	ResNet-18				ResNet-18-SE				ResNet-18-CBAM			
		32/0	32/0.1	64/0	64/0.1	32/0	32/0.1	64/0	64/0.1	32/0	32/0.1	64/0	64/0.1
3×10^{-4}	1×10^{-4}	92.35	92.94	92.06	92.16	92.06	93.63	92.75	93.43	92.94	91.67	92.94	94.12
3×10^{-4}	1×10^{-5}	92.25	91.57	92.45	92.65	92.94	93.53	92.84	93.24	92.65	92.16	92.94	92.94
1×10^{-3}	1×10^{-4}	76.86	88.43	83.53	91.18	76.37	87.35	90.20	92.06	81.18	86.47	82.16	90.49
1×10^{-3}	1×10^{-5}	88.73	87.94	83.14	91.47	85.00	84.90	85.69	92.35	78.24	85.98	80.88	92.35

表 22: ResNet-34 预训练模型搜索结果总表

学习率	权重衰减	ResNet-34				ResNet-34-SE				ResNet-34-CBAM			
		32/0	32/0.1	64/0	64/0.1	32/0	32/0.1	64/0	64/0.1	32/0	32/0.1	64/0	64/0.1
3×10^{-4}	1×10^{-4}	86.37	90.59	92.45	92.65	84.61	93.43	92.75	93.33	87.84	91.37	88.14	93.92
3×10^{-4}	1×10^{-5}	86.57	92.55	92.06	91.47	85.20	92.94	89.61	92.84	84.12	92.16	87.06	92.75
1×10^{-3}	1×10^{-4}	73.82	82.06	66.96	91.47	76.76	83.43	82.75	89.90	70.29	88.14	79.31	89.51
1×10^{-3}	1×10^{-5}	74.90	84.80	81.67	89.12	72.45	84.90	79.61	92.16	76.47	84.41	77.25	92.45

表 23: 从零训练 ResNet 搜索结果总表

学习率	权重衰减	ResNet-18 scratch				ResNet-34 scratch			
		32/0	32/0.1	64/0	64/0.1	32/0	32/0.1	64/0	64/0.1
3×10^{-4}	1×10^{-4}	57.55	51.27	48.63	54.02	55.20	61.67	51.96	60.78
3×10^{-4}	1×10^{-5}	52.75	47.84	53.43	50.69	53.43	60.10	51.67	57.25
1×10^{-3}	1×10^{-4}	51.18	59.12	48.73	49.71	52.94	48.73	50.29	56.76
1×10^{-3}	1×10^{-5}	53.14	44.61	47.75	54.51	48.73	59.02	46.86	47.65

表 24: Transformer 模型搜索结果总表

学习率	权重衰减	ViT-B/16				Swin-T			
		16/0	16/0.1	32/0	32/0.1	16/0	16/0.1	32/0	32/0.1
1×10^{-4}	1×10^{-4}	94.51	94.22	94.90	95.00	94.22	95.98	94.71	95.98
3×10^{-4}	1×10^{-4}	42.75	42.25	48.92	50.10	89.90	93.24	91.67	95.49